

TOK ZPRACOVÁNÍ JEDNOHO PŘÍPADU (SLOŽKA PDF)



DATOVÁ VRSTVA

• **Tabulky:** ares_raw, uw_documents, uw_attributes, uw_rule_results, uw_vectors, uw_feedback

• **Vektory:** první strana dokumentu a shrnutí případu; klíč dokument + model, vektory modelů se nemíchají

• **Sémantická vrstva** (YAML): metriky a dimenze → bezpečné SQL (whitelist, parametry)

• **MCP server** (14 nástrojů): podobné dokumenty, příklady, precedenty případů, statistika pravidel, zpětná vazba

• **Úložiště:** SQLite (vývoj) → PostgreSQL + pgvector (škálování)

MODELY (BEDROCK, EU PROFILY eu.*) - CENA LISTOVÁ, USD / 1M TOKENŮ VSTUP / VÝSTUP

Model	Cena	Použití
Haiku 5.5	0,10 / 0,50	hlavička, segmentace, 1. extrakce, rozhodce shody
Sonnet 5.5	2 / 10	nejistá klasifikace, 1. eskalace extrakce, agent
Opus 5.5	4 / 20	jen 2. eskalace u těžkých skenů
Titan Text Embeddings V2		- vektory (vícejazyčné), kNN báze
K benchmarku		- Nova 2 Lite (vizuální, levnější), Cohere Embed v4 (obrazové vektory stran)

Cena je Anthropic první strany; Bedrock ji má samostatnou. Model pro každý krok je v konfiguraci, vybírá se podle měření na evaluační sadě.

TECH STACK

• Python 3.11, pydantic, YAML konfigurace

• boto3 · Bedrock Converse (obrazové bloky)

• PyMuPDF, Pillow, reportlab (syntetická data)

• SQLAlchemy 2, numpy (kNN)

• FastAPI, Streamlit, MCP SDK (studio)

• pytest (45+ testů), evaluace proti truth.json

ODHAD ČÍSEL (NE MĚŘENÍ)

• **Náklad na případ:** asi 0,05–0,20 USD proti 0,43 USD v PoV (GPT-5.2 + Azure OCR, únor 2026). Úspora z kaskády Haiku → Sonnet, cache a rychlé cesty z báze.

• **Přesnost pravidel:** PoV 97,2 % (140/144, interval 93–99 %). Cíl 98–99,5 %: vizuální čtení odstraní chyby OCR, segmentace řeší dva dokumenty v jednom skenu.

• Rozdíl pod ~3 p. b. se na 144 pravidlech nedá prokázat, proto vlastní sady eval_a–d (60 případů, 660 pravidel; rozliší rozdíl kolem 1 p. b.).

STAV A RIZIKA

• Pipeline, báze, pravidla, MCP a UI běží a jsou testované v mock režimu.

• Vizuální cesta je ověřená jen na falešném modelu; účet zatím neumožňuje volání Bedrocku.

• Textract není v eu-north-1, proto vizuální model místo OCR.

• Mock embeddingy jsou lexikální; práh báze se kalibruje až na Titanu.

RESPONSIBLE AI A COMPLIANCE

• U každé hodnoty strana a citace; model bez důkazu hodnotu nevrací.

• Strojové štítky nehlasují, dokud je člověk nepotvrdí.

• Lidské schválení u každého nálezu; model rozhoduje jen hraniční shody.

• EU region a profily eu.* ; jen syntetická data, žádné reálné osobní údaje.

• MCP smí číst jen složky pod povoleným kořenem.