Underwriting asistent – technická flow

Hackathon track 06 (back-office) · dokumenty → pravidla → znalostní báze · AWS Bedrock, region **eu-central-1** (profily eu.*) · pouze syntetická data

TOK ZPRACOVÁNÍ JEDNOHO PŘÍPADU (SLOŽKA PDF)

1 Vstup

Složka případu: born-digital PDF i **skeny**, různé názvy souborů (název se nepoužívá).

Streamlit upload · složka / S3

2 Předzpracování

Je textová vrstva? **Ano** → text + podpisy z vektorových kreseb (zdarma). **Ne** → obrázky stran 110 dpi + autocontrast.

PyMuPDF · Pillow · bez OCR

3 Hlavička a segmentace

Jen sken: přepis nadpisu a hlavičky; rozdělení souboru na dokumenty (dva dokumenty v jednom skenu).

Haiku 4.5 · Converse + image

4 Klasifikace

Vektor hlavičky → **kNN v znalostní bázi** (hlasují jen ověřené štítky). Shoda ≥ práh = hotovo **bez LLM**. Jinak model s příklady z báze.

Titan Embed V2 · Sonnet 4.5

5 Extrakce

Jen atributy daného typu (z `taxonomy.yaml`) → JSON: hodnota, strana, citace, jistota. **Eskalace** při nízké jistotě, neplatném IČO, nečitelné ceně.

Haiku 4.5 → Sonnet 4.5 → Opus 4.5

6 Pravidla

Rules engine z YAML: konzistence, přítomnost, **KYC**, podpisy (11 pravidel). Shoda bez diakritiky, mezer a právní formy; hraniční případ rozhodne model.

Python · ARES · VIES · Haiku 4.5

7 Výstup a učení

Report a semafor s důkazy. **Člověk potvrdí / opraví typ** → dokument se stane ověřeným příkladem báze. Agent přes MCP: „proč selhalo pravidlo X?“

Streamlit · MCP · Sonnet 4.5

DATOVÁ VRSTVA

- **Tabulky:** `ares_raw`, `uw_documents`, `uw_attributes`, `uw_rule_results`, `uw_vectors`, `uw_feedback`
- **Vektory:** první strana dokumentu a shrnutí případu; klíč dokument + model, vektory modelů se nemíchají
- **Sémantická vrstva** (YAML): metriky a dimenze → bezpečné SQL (whitelist, parametry)
- **MCP server** (14 nástrojů): podobné dokumenty, příklady, precedenty případů, statistika pravidel, zpětná vazba
- **Úložiště:** SQLite (vývoj) → PostgreSQL + pgvector (škálování)

MODELY (HACKATHONOVÝ ÚČET) – USD / 1M TOKENŮ VSTUP / VÝSTUP, LIMIT TÝMU

Model	Cena	Použití
Haiku 4.5	1,10 / 5,50	hlavička, segmentace, 1. extrakce, rozhodce shody (50 req/min)
Sonnet 4.5	3,30 / 16,50	nejistá klasifikace, 1. eskalace, agent (50 req/min)
Opus 4.5	5,50 / 27,50	jen 2. eskalace u těžkých skenů (25 req/min)
Titan Embed V2	–	vektory kNN; v seznamu hackathonu není → ověřit, záloha mock hash
K benchmarku	–	Nova 2 Lite (vizuální, 8M tok/min); Qwen3-235B, GPT-OSS-120B (jen text, 100M tok/min) na hromadné evaluace

Ceny a limity z návodu organizátorů. Claude 5 na účtu není. Cachovaný vstup je 10× levnější. Model pro každý krok je v konfiguraci (`UW_MODEL_*`) a vybírá se podle měření.

TECH STACK

- Python 3.11, pydantic, YAML konfigurace
- boto3 · Bedrock Converse (obrazové bloky)
- PyMuPDF, Pillow, reportlab (syntetická data)
- SQLAlchemy 2, numpy (kNN)
- FastAPI, Streamlit, MCP SDK (stdio)
- pytest (45+ testů), evaluace proti `truth.json`

ODHAD ČÍSEL (NE MĚŘENÍ)

- **Náklad na případ:** asi 0,20–0,40 USD (profil PoV 131 tis. vstup / 10 tis. výstup: Haiku 4.5 0,20; Sonnet 4.5 0,60; kaskáda ≈ 0,28) proti 0,43 USD v PoV. Úspora z cache a rychlé cesty z báze; výrazně nižší jen s Nova nebo Qwen.
- **Přesnost pravidel:** PoV 97,2 % (140/144, interval 93–99 %). Cíl 98–99,5 %: vizuální čtení odstraní chyby OCR, segmentace řeší dva dokumenty v jednom skenu.
- Rozdíl pod ~3 p. b. se na 144 pravidlech nedá prokázat, proto vlastní sady `eval_a–d` (60 případů, 660 pravidel; rozliší rozdíl kolem 1 p. b.).

STAV A RIZIKA

- Pipeline, báze, pravidla, MCP a UI běží a jsou testované v mock režimu.
- Vizuální cesta je ověřená jen na falešném modelu; živě se ověří na hackathonovém účtu (`check_aws.py`).
- Limit týmu 50 req/min (Opus 25): sken ≈ 15 volání, tedy ~3 případy/min; lokální brzda a opakování, hromadné testy na Qwen/Nova.
- Mock embeddingy jsou lexikální; práh báze se kalibruje až na Titanu.

RESPONSIBLE AI A COMPLIANCE

- U každé hodnoty strana a citace; model bez důkazu hodnotu nevrací.
- Strojové štítky nehlasují, dokud je člověk nepotvrdí.
- Lidské schválení u každého nálezu; model rozhoduje jen hraniční shody.
- EU region a profily `eu.*`; jen syntetická data, žádné reálné osobní údaje.
- MCP smí číst jen složky pod povoleným kořenem.

Repo: Mavorte/hackaton_kb (claude/hackathon-next) · spuštění: `streamlit run src/kb/ui.py`

Legenda: model · technologie · bez LLM / bez OCR